

Laboratorio 6

Análisis de redes sociales

Informe de avance: ejercicios 1 a 4

Milton Polanco
Osman de León

Resumen del avance

Este avance cubre la carga e integración, el diagnóstico de calidad, el preprocesamiento, el análisis exploratorio y la construcción de la red bipartita autor-video. Los dos archivos contienen 293 videos, 97 canales, 406 comentarios principales y 332 autores. Todos los comentarios se asociaron con un video por medio de *video_id*; sin embargo, los comentarios cubren únicamente 19 videos. Esta diferencia de cobertura condiciona la interpretación de la participación.

La red se construyó sin inferir respuestas entre usuarios. Una arista indica solamente que un autor publicó un comentario principal en un video, y su peso corresponde al número de comentarios de ese par. Se conservaron los videos sin comentarios como nodos aislados para que la visualización represente el universo completo del archivo de videos. Las proyecciones, comunidades, centralidades formales y el análisis de sentimiento pertenecen a ejercicios posteriores y no se presentan como resultados concluidos en este avance.

1. Carga, comprensión e integración de los datos

1.1 Unidad de observación y llaves

Archivo	Unidad de observación	Llave	Dimensión original
youtube_videos.csv	Un video publicado en YouTube	video_id	293 x 20
youtube_comments.csv	Un comentario principal en un video	comment_id	406 x 17

En el archivo de videos, *channel_id* identifica al canal y *video_id* identifica al contenido. En comentarios, *author_channel_id* corresponde a la cuenta que escribió y no debe confundirse con *channel_id*, que identifica al canal propietario del video. Los nombres y handles se usan únicamente como etiquetas legibles.

1.2 Relación entre las entidades

Un canal puede publicar varios videos; cada video tiene una categoría y pudo recuperarse mediante una o más consultas de búsqueda. Un autor puede dejar comentarios en uno o más videos, y cada comentario principal pertenece a un solo video. La consulta describe cómo se recolectó el registro, no necesariamente el tema final del contenido. Por ello, no se utilizó *source_query* como una clasificación temática definitiva.

1.3 Integración

Se aplicó una unión izquierda desde comentarios hacia videos con *video_id* y se validó la cardinalidad muchos-a-uno. Los 406 comentarios (100.0 %) encontraron una coincidencia y no hubo llaves huérfanas. Después de la unión tampoco se observaron discrepancias en título, nombre de canal o *channel_id* entre las columnas redundantes.

2. Calidad, limpieza y preprocesamiento

2.1 Diagnóstico inicial

No se encontraron filas completas duplicadas ni llaves primarias repetidas. En comentarios hay dos variables constantes: *is_pinned* es falso en todos los registros y *viewer_rating* está vacío. Los faltantes relevantes se resumen a continuación.

Conjunto	Variable	Vacios	Porcentaje
videos	published_time	13	4.4 %
videos	view_count_text	13	4.4 %
videos	description_snippet	25	8.5 %
videos	description	26	8.9 %
comentarios	like_count_text	189	46.6 %
comentarios	viewer_rating	406	100.0 %

Los 13 vacíos de *view_count_text* no implican que falte el conteo analítico, pues *view_count* está completo. En 53 de los 280 textos de vistas convertibles, el valor visible no coincide exactamente con *view_count*; se conserva este último por ser la variable numérica entregada y se interpreta la diferencia como evidencia de capturas en momentos o interfaces distintas.

2.2 Valores atípicos

El criterio de 1.5 rangos intercuartílicos se utilizó como diagnóstico, no como regla de eliminación. Los valores altos son plausibles en métricas de plataformas y contienen información sobre concentración. Por esa razón no se recortaron ni se imputaron.

Variable	Q1	Mediana	Q3	Límite superior	Casos	Máximo
view_count	215	1 175	7 465	18 340	49	8 190 449
like_count	0	1	2	5	48	405
reply_count	0	0	0	0	30	7

2.3 Consistencia y variables de uso delicado

Los identificadores no presentan espacios externos después de la normalización. Cada *channel_id* se asocia con un solo nombre y handle, y cada *author_channel_id* mantiene un nombre y handle dentro de esta muestra. Además, *publish_date* coincide con *upload_date* en los 293 videos, mientras que *owner_handle* coincide con *channel_handle*. La ausencia de contradicciones internas no garantiza que los nombres visibles permanezcan estables fuera del momento de recolección.

- *viewer_rating* se excluye porque carece de datos; *is_pinned* no se usa como predictor porque no varía.
- *published_time* y *published_text* son tiempos relativos; no se transforman en fechas exactas.
- *reply_count* mide respuestas recibidas, pero no identifica autores ni crea aristas entre usuarios.
- *source_query* y *dataset_sources* documentan el muestreo; no se interpretan como tema o preferencia del usuario.

2.4 Conversión de conteos

La función de conversión elimina espacios y la palabra "vistas", reconoce comas o puntos como separadores y admite sufijos K y M. Los valores imposibles se convierten en ausentes para que puedan auditarse. En *like_count_text*, 189 celdas en blanco se transformaron en cero porque corresponden a la representación sin cifra de la interfaz; no se aplicó esta regla a vistas. *reply_count* ya estaba en formato entero.

2.5 Preparación del texto

Se conservaron dos columnas. *texto_original* mantiene el comentario sin cambios y se utilizará para auditoría y sentimiento. *texto_limpio* se convirtió a minúsculas; eliminó URL, menciones, puntuación, cifras y emojis; conservó las letras con tilde; separó hashtags y guiones bajos; y retiró una lista explícita de palabras vacías en español. No se aplicó lematización en este avance: sin un modelo contextual validado para español guatemalteco, una reducción automática puede alterar nombres propios, modismos y errores ortográficos.

Indicador	Resultado
Comentarios modificados	403 de 406
Textos vacíos antes / después	0 / 6
Duplicados antes / después	2 / 12
Registros eliminados	0

Los seis textos vacíos posteriores no se eliminaron: continúan siendo comentarios válidos para los conteos y para la red, aunque se excluyen de frecuencias léxicas. El aumento de duplicados de 2 a 12 es esperable porque expresiones distintas pueden reducirse a la misma secuencia después de retirar signos, menciones y palabras vacías.

3. Análisis exploratorio

3.1 Alcance y distribuciones

Elemento	Cantidad
Videos	293
Canales	97
Comentarios principales	406
Autores únicos	332
Videos con al menos un comentario	19

Las visualizaciones por video tienen mediana de 1 175, rango intercuartílico de 215 a 7 465 y máximo de 8 190 449. Los comentarios reciben una mediana de 1 me gusta; 189 tienen cero y el máximo es 405. Solo 30 comentarios (7.4 %) registran al menos una respuesta, con un máximo de 7. Estas distribuciones son asimétricas y no se resumen adecuadamente solo con el promedio.

3.2 Videos y canales con mayor participación

Video	Canal	Comentarios	Autores	Vistas
Qué rico come tu diputado	Quorum	161	128	11 775
La cooptación de Walter Mazariegos en l...	Quorum	50	49	10 156
Inician los trabajos de recuperación de...	Gobierno de la Repúbli...	45	32	11 670
Plan 2032 Ciudad de Guatemala	Municipalidad de Guate...	25	25	304 089
EE.UU. envía a mexicanos deportados a G...	Noticias Telemundo	25	18	14 200
Conferencia de Prensa del Gobierno de G...	Gobierno de la Repúbli...	25	19	3 628
Arroz con pollo a la MONOPOLIO	Quorum	16	16	1 954




Figura 1. Diez videos con más comentarios observados.

El video "Qué rico come tu diputado" reúne 161 comentarios y 128 autores: por sí solo representa 39.7 % de los comentarios. Los dos primeros videos pertenecen a Quorum y suman 211 comentarios. El número de autores es cercano al número de comentarios en la mayoría de videos, pero el peso repetido en algunos pares muestra que no toda la actividad proviene de participantes distintos.




Figura 2. Canales con más comentarios observados.

Quorum concentra 256 comentarios (63.1 %) y 214 autores únicos. Gobierno de la República de Guatemala ocupa el segundo lugar con 70 comentarios. La Municipalidad de Guatemala y Noticias Telemundo registran 25 cada uno. Esta distribución refleja tanto el interés observado como la selección de videos de los que se recolectaron comentarios.

3.3 Concentración de la participación




Figura 3. Porcentaje acumulado de comentarios al ordenar los videos de mayor a menor actividad.

Los cinco videos con mayor actividad contienen 75.4 % de los comentarios y los primeros diez alcanzan 93.6 %. A nivel de canal, los cinco primeros concentran 96.1 %. Además, 274 videos no cuentan con comentarios en el archivo. Estos ceros describen la cobertura disponible; no demuestran que los videos no hayan recibido comentarios en YouTube.

3.4 Popularidad y participación




Figura 4. Relación entre vistas y comentarios. Se utilizan escalas logarítmicas para mostrar la dispersión.

Al considerar los 293 videos, la correlación de Spearman entre vistas y comentarios es 0.080 y la de Pearson es -0.008; no aparece una asociación global relevante. Entre los 19 videos que sí tienen comentarios, Spearman aumenta a 0.811. Esta diferencia no debe interpretarse como efecto causal: los comentarios se recolectaron solo para una selección de videos, y vistas y comentarios pueden corresponder a momentos de captura distintos.

3.5 Categorías, consultas y contenido textual

La categoría más numerosa es News & Politics, con 138 videos y 335 comentarios. Entertainment contiene 48 videos y 70 comentarios. People & Blogs tiene 66 videos pero ninguno de sus registros aparece en el archivo de comentarios. Las consultas con más videos incluyen cuentas gubernamentales y búsquedas como "guatemala noticias", "guatemala transporte" y "guatemala tráfico". Estas frecuencias evidencian el diseño de recolección y no una distribución natural de temas en toda la plataforma.

Terminos frecuentes en comentarios limpios




Figura 5. Palabras y bigramas más frecuentes después de la limpieza.

Las palabras más frecuentes son "pueblo" (56), "guatemala" (52), "dinero" (34), "presidente" (32), "país" (31), "trabajo" (30) y "diputados" (28). Entre los bigramas destacan "presidente Bernardo" (9), "Bernardo Arévalo" (8), "ciudad Guatemala" (6) y "pacto corruptos" (5). El contenido observado se concentra en política, gestión pública, economía cotidiana, seguridad y movilidad urbana.




Figura 6. Hashtags en títulos, descripciones y comentarios.

#guatemala es el hashtag dominante (48 apariciones), seguido de #larondagt (29) y #noticias (14). También aparecen etiquetas promocionales como #like, #comenta y #comparte; por ello, la frecuencia de un hashtag no equivale de forma automática a relevancia temática.

3.6 Respuestas a las preguntas obligatorias

¿Qué videos y canales concentran la mayor participación?

"Qué rico come tu diputado" reúne 161 comentarios, seguido de "La cooptación de Walter Mazariegos en la USAC" con 50 y "Inician los trabajos de recuperación del Puente Belice" con 45. Quorum concentra 256 comentarios y Gobierno de la República de Guatemala 70.

¿Existen audiencias compartidas entre videos, canales o temas?

Sí, pero son reducidas: se encontraron 11 pares de videos con al menos un autor en común. El máximo observado es de dos autores compartidos, tanto entre los videos de Quorum sobre USAC y diputados como entre sus videos sobre internet y arroz. La evidencia describe co-participación, no interacción directa.

¿Qué autores funcionan como puentes?

Nueve autores comentaron más de un video. @hashojea7348 y @inge_vergueta participaron en tres videos cada uno; los otros siete participaron en dos. En este avance se consideran candidatos descriptivos a puente por su recurrencia. La afirmación estructural se evaluará después con centralidad e impacto de remoción.

¿Qué temas y sentimientos caracterizan a las principales comunidades?

Todavía no se han estimado comunidades ni sentimiento, porque corresponden a los ejercicios 7 y 9. El vocabulario permite ubicar temas preliminares de política, gasto público, trabajo, seguridad y ciudad, pero no se asignan etiquetas emocionales sin un método validado para español. Esta separación evita presentar una impresión de lectura como resultado cuantitativo.

¿La visibilidad coincide con la participación?

No en el conjunto completo: Spearman = 0.080. El video con más vistas alcanza 8 190 449 y no tiene comentarios en el archivo, mientras que el video más comentado tiene 11 775 vistas. La coincidencia aparente entre los 19 videos cubiertos no compensa el sesgo de selección.

¿Qué conclusiones están limitadas por la recolección?

Las consultas dirigieron la selección, los comentarios cubren solo 19 videos, las fechas relativas no son marcas temporales exactas y los conteos son fotografías de un momento. Además, no se conoce quién respondió a quién. Por tanto, los resultados se limitan a la muestra entregada y no se generalizan a Guatemala ni a todos los usuarios de YouTube.

3.7 Preguntas adicionales

1. ¿La mayor parte de comentarios recibe respuestas?

No. Solo 30 de 406 comentarios (7.4 %) tienen al menos una respuesta registrada; 376 tienen cero.

2. ¿La participación recurrente es común?

No. Nueve de 332 autores (2.7 %) comentaron en más de un video, y ninguno aparece en más de tres.

3. ¿Todos los comentarios reciben señales de aprobación?

No. Un total de 189 comentarios (46.6 %) se registró sin cifra de me gusta y se codificó como cero; 217 tienen al menos uno.

4. Construcción de la red bipartita autor-video

4.1 Definición

La red es no dirigida y tiene dos tipos de nodo: autores y videos. Se crea una arista cuando un *author_channel_id* publicó al menos un comentario principal en un *video_id*. El peso es el número de comentarios distintos de ese autor en ese video. La arista no significa amistad, respuesta, conversación directa, acuerdo ni aprobación; representa únicamente participación observada en el mismo contenido.

Elemento	Cantidad
Nodos totales	625
Nodos autor	332
Nodos video	293
Aristas autor-video	343
Suma de pesos	406
Videos aislados en los datos	274

Hay 343 combinaciones únicas autor-video y la suma de pesos es 406, igual al número de comentarios. Esta igualdad verifica que la agregación no perdió registros. Los 274 videos aislados se mantienen en la tabla de nodos; representan ausencia de comentarios en el archivo, no aislamiento social ni ausencia real de comentarios en YouTube.

4.2 Tablas de nodos y aristas

La tabla de nodos contiene identificador prefijado, tipo, etiqueta, grado, grado ponderado y atributos propios. La tabla de aristas contiene origen autor, destino video, peso y las llaves originales. Los archivos completos se guardaron en *reporte/tablas/nodos_bipartita.csv* y *reporte/tablas/aristas_bipartita.csv*.

Tipo	Etiqueta	Grado	Grado ponderado
video	Qué rico come tu diputado	128	161
autor	@eugeneramirez4405	1	6

4.3 Visualización completa




Figura 7. Red completa. Los círculos son autores y los cuadrados son videos; a la derecha se ubican componentes pequeños y videos sin aristas.

La visualización incluye los 625 nodos y las 343 aristas. La estructura grande está dominada por contenidos con mayor cantidad de comentarios, mientras que la franja de nodos separados hace visible la falta de cobertura para la mayoría de videos. No se eliminaron nodos ni aristas para mejorar la apariencia. La posición proviene de un algoritmo de fuerzas y solo ayuda a leer conectividad; la distancia geométrica no es una medida sustantiva.

Alcance de la entrega

Este documento cierra el avance solicitado para los ejercicios 1 a 4. Quedan fuera las proyecciones autor-autor y video-video, la topología comparada, las comunidades, las centralidades definitivas y el sentimiento. Los archivos limpios, la integración, las tablas de red, las figuras y el código reproducible quedan preparados para continuar esos análisis sin cambiar las decisiones metodológicas documentadas aquí.