

Universidad del Valle de Guatemala
Facultad de Ingeniería
Departamento de Ciencias de la Computación
CC3084 – Data Science

Laboratorio 6

Análisis de redes sociales

Informe final – ejercicios 1 a 10

Milton Polanco
Osman de León

Guatemala, 6 de septiembre de 2026

<https://github.com/MiltonPolanco/Lab-6-Data-ScienceCC3084>

Resumen

Este informe integra el análisis completo de dos conjuntos de datos de YouTube (293 videos, 97 canales, 406 comentarios y 332 autores, de los cuales solo 19 videos tienen comentarios en el archivo). Se cubre la carga e integración, el diagnóstico de calidad, la limpieza, el análisis exploratorio, la red bipartita autor-video y sus proyecciones autor-autor y video-video, la topología y fragmentación de las tres redes, la detección de comunidades, la centralidad y los participantes puente, el análisis de sentimiento y las conclusiones. Los hallazgos centrales son consistentes entre secciones: la participación está muy concentrada en pocos videos y canales, es mayoritariamente no recurrente, y la estructura de red resultante está fragmentada por pieza de contenido más que interconectada entre videos o canales.

1 Carga, comprensión e integración

Cada fila de `youtube_videos.csv` representa un video (llave `video_id`, 293 filas, 20 variables); cada fila de `youtube_comments.csv` representa un comentario principal (llave `comment_id`, 406 filas, 17 variables). `channel_id` identifica al canal dueño del video; `author_channel_id` identifica a quien comenta, y nunca deben confundirse. `source_query` describe el procedimiento de muestreo, no el tema del video, por lo que no se usó como clasificación temática.

La integración se hizo con una unión izquierda desde comentarios hacia videos por `video_id`, validada como muchos-a-uno: los 406 comentarios (100 %) encontraron coincidencia, sin llaves huérfanas ni discrepancias en título, nombre de canal o `channel_id` tras la unión.

2 Calidad, limpieza y preprocesamiento

Conjunto	Filas	Columnas	Faltantes	Duplicados	Constantes
Videos	293	20	77	0	0
Comentarios	406	17	595	0	2

Tabla 1: Diagnóstico inicial de calidad.

Las dos variables constantes en comentarios son `is_pinned` (siempre *False*) y `viewer_rating` (100 % vacía); ambas se excluyen del análisis por no aportar variabilidad. Los faltantes relevantes son `like_count_text` (46.6 %, se codifican como cero porque representan la ausencia de cifra en la interfaz de YouTube) y `view_count_text / description / description_snippet` en videos (4.4 %–8.9 %, no afectan `view_count`, que es la variable numérica usada para cálculos). Los valores atípicos de `view_count`, `like_count` y `reply_count` (criterio 1.5 RIC) se diagnostican pero no se recortan, por ser plausibles en métricas de plataforma. No se detectaron identificadores duplicados ni ambigüedades entre `channel_id`/`author_channel_id` y sus nombres o handles visibles.

Se conservaron dos versiones de texto: `texto_original` (para auditoría y sentimiento) y `texto_limpio` (minúsculas, sin URL ni menciones, hashtags separados en palabras, sin puntuación, cifras ni emojis, y sin palabras vacías en español; no se aplicó lematización por falta de un modelo validado para español guatemalteco). El efecto de la limpieza: 403 de 406 comentarios se modificaron, los textos vacíos pasaron de 0 a 6 y los duplicados de 2 a 12 (aumento esperable al retirar signos y palabras vacías); no se eliminó ningún registro.

3 Análisis exploratorio

Elemento	Cantidad
Videos	293
Canales	97
Comentarios	406
Autores únicos	332
Videos con al menos un comentario	19

Tabla 2: Resumen general.




Figura 1: Videos y canales con más comentarios observados.

“*Qué rico come tu diputado*” (Quorum) concentra 161 comentarios (39.7 % del total) y 128 autores; Quorum como canal concentra 256 comentarios (63.1 %) y 214 autores únicos. La concentración es extrema: los 5 videos más activos reúnen 75.4 % de los comentarios y los primeros 10, 93.6 %; a nivel canal, los 5 primeros concentran 96.1 %.




Figura 2: Concentración de comentarios por video y relación entre vistas y comentarios.

La relación entre visualizaciones y comentarios es débil en los 293 videos (Spearman = 0.080, Pearson = -0.008), pero sube a 0.811 entre los 19 videos comentados; esta diferencia refleja el sesgo de selección de la muestra y no debe interpretarse como causal. La categoría más numerosa es *News & Politics* (138 videos, 335 comentarios); *People & Blogs* tiene 66 videos y ningún comentario en el archivo.




Figura 3: Palabras, bigramas y hashtags más frecuentes tras la limpieza.

Las palabras más frecuentes son “pueblo” (56), “guatemala” (52) y “dinero” (34); entre los bigramas destacan “presidente bernardo” (9) y “pacto corruptos” (5). El hashtag dominante es #guatemala (48 apariciones).

Preguntas obligatorias

- **¿Qué videos y canales concentran la mayor participación?** “Qué rico come tu diputado” (161), “La cooptación de Walter Mazariegos en la USAC” (50) e “Inician los trabajos de recuperación del Puente Belice II” (45); Quorum (256) y Gobierno de la República de Guatemala (70).
- **¿Existen audiencias compartidas?** Sí, pero reducidas: 11 pares de videos comparten al menos un autor, con un máximo de 2 autores compartidos por par.
- **¿Qué autores funcionan como puentes?** Nueve autores comentaron en más de un video; @inge_vergueta y @hashoj ea7348 en tres cada uno (se profundiza en la sección 8).
- **¿Qué temas y sentimientos caracterizan las comunidades?** No corresponden a este ejercicio (se resuelven en las secciones 7 y 9).
- **¿La visibilidad coincide con la participación?** No en el conjunto completo (Spearman = 0.080); el video más visto (8,190,449 vistas) no tiene comentarios en el archivo.
- **¿Qué limita las conclusiones?** La selección por consultas, la cobertura de solo 19 videos, las fechas relativas y los conteos de un único momento de captura (ampliado en la sección 10).

Preguntas adicionales

1. *¿La mayoría de comentarios recibe respuestas?* No: solo 30 de 406 (7.4 %) tienen al menos una.
2. *¿La participación recurrente es común?* No: 9 de 332 autores (2.7 %) comentaron en más de un video, y ninguno en más de tres.
3. *¿Todos los comentarios reciben “me gusta”?* No: 189 (46.6 %) se registraron sin cifra (codificados como cero) y 217 tienen al menos uno.

4 Red bipartita autor-video

La red bipartita no dirigida tiene 625 nodos (332 autores, 293 videos) y 343 aristas; cada arista indica que un autor publicó al menos un comentario en un video, y su peso es el número de comentarios de ese par (sin representar amistad, respuesta directa ni aprobación). La suma de pesos (406) coincide con el número de comentarios, lo que verifica que la agregación no perdió registros. Se conservan los 274 videos sin comentarios como nodos aislados para representar la cobertura real de los datos entregados.




Figura 4: Red bipartita autor-video completa (625 nodos, 343 aristas).


5 Proyecciones de la red

Se construyen dos proyecciones: **autor-autor** (dos autores se conectan si comentaron el mismo video; peso = videos compartidos) y **video-video** (dos videos se conectan si comparten al menos un autor; peso = autores compartidos).

Proyección	Nodos	Aristas	Peso máximo
Autor-autor	332	10,732	2 (videos compartidos)
Video-video	293	11	2 (autores compartidos)

Tabla 3: Tamaño de las proyecciones.

Proyeccion autor-autor (componente principal, n=276)
 circulos rojos: los 9 autores recurrentes (comentaron en mas de un video)



Proyeccion video-video (nodos con al menos una arista, n=10)




Figura 5: Componente principal de la proyección autor-autor, con los 9 autores recurrentes resaltados en rojo (izq.), y proyección video-video completa (der.).

Aunque la proyección autor-autor tiene muchas aristas, esto es un artefacto de que cada video concentrado (p. ej. 128 autores en un solo video) genera por sí solo miles de pares posibles: ningún par de autores coincidió en más de 2 de los 19 videos comentados. La proyección video-video, en cambio, es casi vacía (11 aristas entre 293 nodos), lo que confirma que las audiencias compartidas entre piezas de contenido son reales pero marginales. La primera describe comunidades de comentaristas que conviven en el mismo espacio de discusión (sin implicar interacción directa); la segunda describe solapamiento de audiencia observada entre videos.

6 Topología y fragmentación

Red	Nodos	Aristas	Densidad	Grado medio	Componentes	% comp. mayor
Bipartita autor-video	625	343	0.0018	1.10	284	45.8
Proyección autor-autor	332	10,732	0.1953	64.65	10	83.1
Proyección video-video	293	11	0.0003	0.08	284	3.4

Tabla 4: Topología comparada de las tres redes.




Figura 6: Distribución de grados en la red bipartita (nótese la escala logarítmica en autores).

La distribución de grados es fuertemente asimétrica: 323 de 332 autores (97.3 %) comentaron una sola vez, mientras que un video llega a 128 autores distintos. La red bipartita está muy fragmentada (284 componentes; la mayor cubre 45.8 % de los nodos); esto se explica porque solo 19 videos tienen comentarios y cada uno tiende a formar su propio componente. La proyección autor-autor concentra 83.1 % de sus nodos en una sola componente y solo 4 autores quedan aislados, pero su cohesión aparente es engañosa: el coeficiente de agrupamiento bipartito promedio es 0.501, mientras que el coeficiente de Robins–Alexander (diseñado específicamente para bipartitas y más robusto a este sesgo) es apenas 0.008. La transitividad de la proyección autor-autor (0.984) es un artefacto de que cada video forma una casi-clique entre sus comentaristas, no evidencia de cohesión social real. La proyección video-video, con transitividad 0.316 pero clustering promedio 0.010, está dominada por unos pocos triángulos aislados entre videos con audiencia compartida.

Elemento	Cantidad
Videos sin comentarios en el archivo (grado 0, bipartita)	274
Autores que comentaron una sola vez (grado 1, bipartita)	323
Autores aislados en la proyección autor-autor	4
Videos aislados en la proyección video-video	283

Tabla 5: Periferia y aislamiento.

Estos ceros describen *ausencia de datos en la muestra recolectada* (solo 19 de 293 videos tienen comentarios), no aislamiento social real de esos videos o autores en YouTube.

7 Comunidades

Se aplicó el algoritmo de **Louvain** (`networkx.algorithms.community.louvain_communities`, ponderado por el peso de cada arista) sobre la **componente gigante de la red bipartita** (286 nodos), la única con estructura suficiente para que la detección sea informativa; los 339 nodos restantes (videos sin comentarios y componentes triviales) se excluyeron por no aportar estructura comparativa.

Comunidad	Nodos	Autores	Videos
0	125	124	1
1	48	47	1
2	32	29	3
3	31	30	1
4	20	19	1
5	14	13	1
6	8	7	1
7	8	7	1

Tabla 6: Tamaño de las 8 comunidades detectadas (modularidad = 0.704).




Figura 7: Comunidades detectadas en la componente gigante de la red bipartita.

La modularidad (0.704) es alta, pero debe leerse con cautela: como la componente gigante es casi un árbol de estrellas (cada video conecta a sus propios comentaristas, con pocos puentes entre videos), casi cualquier partición que respete esas estrellas obtiene modularidad alta. La **comunidad 0** corresponde casi en su totalidad a “Qué rico come tu diputado” y tiene el sentimiento promedio más negativo de todas (-0.253 , sección 9). La **comunidad 1** agrupa a los comentaristas de “La cooptación de Walter Mazariegos en la USAC” (sentimiento neutro, 0.010). La **comunidad 2** es la única con más de un video (3), lo que indica que agrupa a los pocos autores que sí generaron puentes entre contenidos; es también la más positiva (0.472). Las comunidades restantes siguen el mismo patrón de un video dominante con sus comentaristas, prácticamente sin solaparse entre sí.

8 Nodos centrales y participantes puente

Sobre la red bipartita completa se calcularon grado, grado ponderado, centralidad de intermediación (sin ponderar por peso, ya que este representa intensidad y no una distancia recorrible), cercanía y *PageRank* ponderado.

Autor	Grado	Intermediación	PageRank
@virgiliogarcia3039	2	0.0728	0.0027
@inge_vergueta	3	0.0685	0.0030
@josegil3813	2	0.0556	0.0019
@Jel.Awesh.M	2	0.0280	0.0031
@hashojea7348	3	0.0188	0.0041

Tabla 7: Autores con mayor intermediación en la red bipartita.




Figura 8: Autores puente según intermediación.

De los 332 autores, solo los 9 recurrentes (que comentaron en más de un video) tienen intermediación mayor a 0; de ellos, **7 son puntos de articulación formales** (si se eliminaran, la red se fragmentaría más). Su diversidad de participación es baja: ninguno comentó en más de 3 de los 293 videos, así que “puente” describe aquí una función estructural puntual y no un patrón recurrente de comportamiento. Entre los videos, *PageRank* confirma la jerarquía ya vista por grado: “Qué rico come tu diputado” concentra el mayor alcance (0.150), muy por encima del segundo lugar (0.057). De los 293 videos, **15 son puntos de articulación**: en su mayoría son los mismos videos con más comentaristas, cuya eliminación desconectaría a la mayoría de autores que solo comentaron ahí.

9 Análisis de contenido y sentimiento

Este entorno de trabajo no tiene acceso a internet para descargar modelos preentrenados en español (p.ej. BETO/pysentimiento) ni los recursos adicionales de NLTK; VADER, además, es un léxico calibrado para inglés y no es apropiado para texto en español. Por ello se construyó un **analizador de sentimiento basado en léxico en español** (aprox. 50 palabras positivas y 70 negativas, con vocabulario del dominio observado: corrupción, injusticia, mentira, etc.), aplicado sobre `texto_original` para no perder negaciones. El método invierte la polaridad si un negador (“no”, “nunca”, “jamás”, etc.) aparece dentro de las 3 palabras previas, y amplifica el peso ante intensificadores (“muy”, “tan”). El léxico detectó al menos una palabra de polaridad en solo el **38.9 %** de los comentarios; el resto se clasifica como neutro por falta de cobertura léxica, no necesariamente por ausencia de carga emocional. El método no captura sarcasmo ni jerga muy específica del español guatemalteco, y su vocabulario no fue validado contra una muestra etiquetada, por lo que sus resultados son una aproximación exploratoria.




Figura 9: Distribución de sentimiento y sentimiento promedio por video.

De 406 comentarios, 62.8 % se clasificó como neutro, 19.7 % positivo y 17.5 % negativo. El video más comentado, “Qué rico come tu diputado”, tiene el sentimiento promedio más negativo entre los más activos (-0.252 ; 40 comentarios negativos contra 15 positivos), coherente con el vocabulario de queja hacia diputados. En contraste, “Plan 2032 Ciudad de Guatemala” (Municipalidad de Guatemala) tiene el promedio más positivo entre los más comentados (0.600, sin negativos detectados). Por canal, Quorum es levemente negativo (-0.082), mientras que canales institucionales como la Municipalidad (0.600) y Noticias Telemundo (0.320) son positivos, aunque con muestras mucho más pequeñas (25 comentarios cada uno). Por comunidad, el patrón replica el de videos porque cada comunidad principal está dominada por un solo video: la comunidad 0 es la más negativa (-0.253) y la comunidad 2, la única con varios videos y autores puente, la más positiva (0.472).

10 Interpretación, limitaciones y conclusiones

Hallazgos en contexto

La muestra retrata un patrón de participación **muy concentrado y poco recurrente**: 293 videos y 97 canales, pero comentarios en solo 19 videos, concentrados en 5 de ellos (75.4 %) y en un solo canal, Quorum (63.1 %). El 97.3 % de los autores comentó una sola vez. La red bipartita (284 componentes, dominada por pocas estrellas grandes) y las comunidades detectadas (que coinciden casi uno a uno con videos individuales) describen consistentemente un consumo de contenido **fragmentado por pieza**, no una audiencia interconectada. El sentimiento, con tono mixto pero inclinación negativa en el contenido político de mayor participación, es congruente con el vocabulario de queja identificado desde el análisis exploratorio.

Limitaciones

- **Cobertura de comentarios:** solo 19 de 293 videos (6.5 %) tienen comentarios en el archivo; el resto es ausencia de datos observados, no ausencia real en YouTube.
- **Selección por consultas:** los videos se recolectaron con búsquedas dirigidas (cuentas gubernamentales, “guatemala noticias/transporte/tráfico”), no una muestra representativa de YouTube.
- **Fechas relativas:** `published_time/published_text` no permiten reconstruir una línea temporal exacta.
- **Conteos puntuales:** vistas, comentarios y “me gusta” reflejan un único momento de captura (53 casos de `view_count_text` no coinciden exactamente con `view_count`).
- **Sin relaciones explícitas entre autores:** `reply_count` nunca se usó para construir aristas entre usuarios, porque no identifica a quién respondió.
- **Concentración en pocos videos:** las métricas de red, comunidades y centralidad están dominadas por

un puñado de videos con muchos comentarios.

Descripción, asociación e inferencia

Los resultados son descriptivos o, a lo sumo, asociativos dentro de la muestra (p. ej. la correlación Spearman entre vistas y comentarios sube de 0.080 a 0.811 al restringirse a los 19 videos comentados, sin que eso implique causalidad). Ninguno de estos hallazgos se generaliza a todos los usuarios de YouTube ni a la población de Guatemala.

Conclusión integrada

Integrando redes, contenido, sentimiento y limitaciones: la participación observada es **concentrada, poco recurrente y fragmentada por contenido**. La red bipartita, sus proyecciones y las comunidades detectadas describen el mismo fenómeno desde ángulos distintos: pocos videos concentran casi toda la actividad, casi ningún autor participa en más de un par de videos, y las comunidades con múltiples videos son la excepción. El tono es más negativo en el contenido político de mayor tracción (corrupción, diputados) y más positivo en contenido institucional de menor escala. Cualquier lectura debe mantenerse acotada a la muestra entregada: no representa a todos los usuarios de YouTube ni permite conclusiones causales sobre el clima de opinión en Guatemala.